TOBB ETÜ Bilgisayar Mühendisliği Bölümü
BİL 443/564 Dönem Projesi Ara Rapor

2025-26 Bahar Dönemi

Öğrenci Adı Soyadı:Oruç Çakır **Date: 02/01/2026**

1. Proje ismi

Çoklu Ajan Destekli Açıklanabilir Yapay Zeka Destekli Metin Sınıflandırma Sistemi (Multi-Agent Explainable AI-Enhanced Text Classification System)

2. Proje tanımı

Bu projede, metin verilerinin otomatik olarak kategorilere sınıflandırılması ve sınıflandırma kararlarının açıklanabilir yapay zeka (XAI) yöntemleriyle yorumlanması hedeflenmektedir. Sistem, İngilizce ve Türkçe dillerinde hem binary hem de multi-class sınıflandırma görevlerini desteklemektedir.

Problem: Geleneksel metin sınıflandırma sistemleri kara kutu olarak çalışmakta ve verdikleri kararların nedenini açıklayamamaktadır. Ayrıca farklı veri tipleri ve diller için hangi modelin en uygun olduğunun belirlenmesi kullanıcılar için zordur.

Çözüm: 3 ajandan oluşan çoklu ajan mimarisi geliştirilmiştir:

1. **Niyet Sınıflandırıcı Ajanı:** Kullanıcının metnini analiz ederek dil ve bağlam tespiti yapar, uygun modele yönlendirir.
2. **Sınıflandırıcı Ajanı:** 6 farklı sınıflandırma yöntemi (Naive Bayes, SVM, Random Forest, KNN, Logistic Regression, Transformer) ile metin sınıflandırması yapar.
3. **XAI Ajanı:** LIME, SHAP ve LLM kullanarak sınıflandırma kararlarını insan dostu şekilde açıklar.

Beklenen Sonuçlar: Farklı veri setleri üzerinde 6 modelin performans karşılaştırması, açıklanabilir tahmin sonuçları ve kullanıcı dostu bir arayüz ile interaktif metin sınıflandırma sistemi.

3. Proje metodolojisi, daha önce benzer projelerde kullanılan metotlar hakkında bilgiler, literatür taraması

3.1 Metodoloji

Proje, aşamalı bir geliştirme metodolojisi ile ilerlemektedir:
A. Veri Ön İşleme: Ham metin verisi üzerinde HTML etiket temizleme, URL kaldırma, küçük harfe dönüştürme, noktalama işareti temizleme, stopwords filtreleme ve minimum kelime uzunluğu filtreleme işlemleri uygulanmaktadır. Türkçe ve İngilizce dil desteği mevcuttur.

B. Öznitelik Çıkarımı: İki farklı yöntem kullanılmaktadır:

- TF-IDF: Kelime sıklığına dayalı istatistiksel temsil. Geleneksel ML modelleri için kullanılmaktadır.
- Transformer Tokenization: BERT/DistilBERT modelleri için doğrudan tokenizer kullanılarak metin kodlanmaktadır.

C. Sınıflandırma: 6 farklı yöntem uygulanmaktadır:

4. Naive Bayes
5. SVM
6. Random Forest
7. KNN
8. Logistic Regression
9. Transformer

D. Açıklanabilirlik: Üç katmanlı açıklanabilirlik yaklaşımı:

- LIME: Lokal yorumlanabilir model-agnostik açıklamalar
- SHAP: Shapley değerlerine dayalı öznitelik katkı analizi
- LLM: Doğal dilde insan dostu açıklama üretimi

3.2 Literatür Taraması

3.2.1 Sınıflandırma Yöntemleri

Metin sınıflandırma alanında yaygın olarak kullanılan yöntemler şunlardır:

- **Naive Bayes:** McCallum ve Nigam (1998) tarafından metin sınıflandırmada etkinliği gösterilmiştir. Özellikle yüksek boyutlu TF-IDF vektörlerinde hızlı ve etkili sonuçlar vermektedir.
- **SVM:** Joachims (1998) metin kategorizasyonunda SVM'nin üstün performansını ortaya koymuştur. Yüksek boyutlu uzaylarda etkili sınır belirleme kapasitesi ile metin sınıflandırmada altın standart olarak kabul edilmektedir.
- **Random Forest:** Breiman (2001) tarafından önerilen ensemble yöntemi, birden fazla karar ağacının birleştirilmesiyle overfitting'i azaltmaktadır.
- **KNN:** Cover ve Hart (1967) tarafından temelleri atılan bu yöntem, özellik uzayında en yakın komşulara dayalı sınıflandırma yapmaktadır.
- **Logistic Regression:** Basitliği ve yorumlanabilirliği sayesinde metin sınıflandırmada sıkça tercih edilmektedir.
- **Transformer Modelleri:** Devlin ve ark. (2019) tarafından önerilen BERT, transfer öğrenme ile metin sınıflandırmada çığır açmıştır. Fine-tuning stratejileri (head-only, full, LoRA) ile farklı kaynak kısıtlarına uyum sağlanmaktadır. Hu ve ark. (2022) tarafından önerilen LoRA yöntemi, düşük maliyetli fine-tuning imkanı sunmaktadır.

3.2.2 Veri Setleri Üzerindeki Önceki Çalışmalar

IMDB Veri Seti:

IMDB duygu analizi, metin sınıflandırma alanında en yaygın kullanılan benchmark veri setlerinden biridir. TF-IDF tabanlı geleneksel yöntemlerle yapılan çalışmalarda SVM ve Logistic Regression ~%90 doğruluk elde ederken, Naive Bayes ~%86, Random Forest ~%84 doğruluk göstermiştir [1]. Transformer tabanlı modellerde ise BERT fine-tuning ile ~%93, DistilBERT ile %92.82, XLNet ile %96.21 doğruluk elde edilmiştir [2]. En güncel çalışmalarda RoBERTa-Large tabanlı sentence transformer ve XGBoost kombinasyonu %95.9 doğruluğa ulaşmıştır [3].

Model	Doğruluk	Kaynak
SVM (TF-IDF)	~%90	[1]
Logistic Regression (TF-IDF)	~%90	[1]
Naive Bayes (TF-IDF)	~%86	[1]
Random Forest (TF-IDF)	~%84	[1]
BERT (fine-tuned)	~%93	[2]
DistilBERT	%92.82	[2]
XLNet	%96.21	[2]

AG News Veri Seti:
AG News, 4 kategorili haber sınıflandırma benchmark veri setidir. BERT fine-tuning ile %94.5 doğruluk elde edilmiştir [4]. Geleneksel yöntemlerle (TF-IDF + SVM/LR) %90-91 civarı doğruluk raporlanmıştır. BERT-GRU hibrit modelleri, SVM'ye göre ~9.7 puan daha yüksek doğruluk elde etmiştir [5]. Çalışmalar, geleneksel yöntemlerin hesaplama verimliliği açısından hala rekabetçi olduğunu göstermektedir.

Model	Doğruluk	Kaynak
BERT (fine-tuned)	~%94.5	[4]
BERT + GRU	~%95+	[5]
SVM (TF-IDF)	~%90-91	[5]
Logistic Regression (TF-IDF)	~%90	[5]

Türkçe Duygu Analizi:
Türkçe duygu analizi, düşük kaynaklı dil olması nedeniyle İngilizce'ye kıyasla daha sınırlı çalışılmıştır. Acıkalın ve Bardak (2020) BERTurk modelini Türkçe duygu analizinde kullanarak %90.22 test doğruluğu elde etmiştir [6]. XLM-T modeli %92 doğruluğa ulaşırken, TurkishBERTweet %86, BERTurk %75 performans göstermiştir [7]. Geleneksel ML yöntemleriyle yapılan çalışmalarda DistilBERT ve RoBERTa %80, ALBERT %77 doğruluk elde etmiştir [8].

Model	Doğruluk	Kaynak
XLM-T	%92	[7]
BERTurk	%90.22	[6]
TurkishBERTweet	%86	[7]
DistilBERT (Türkçe)	%80	[8]

TTC4900 Türkçe Haber Sınıflandırma:
Saygın (2018) tarafından oluşturulan TTC4900, 7 kategorili Türkçe haber sınıflandırma benchmark veri setidir [9]. Köksal (2022) geleneksel ve modern yöntemleri karşılaştırarak learning-based algoritmaların Türkçe metin sınıflandırmada başarısını ortaya koymuştur [10]. BERTurk (dbmdz/bert-base-turkish-cased) fine-tuning ile yüksek performans elde edilmiştir [11]. Geleneksel yöntemlerden Random Forest %93.9 doğruluk gösterirken, BERT tabanlı dil modelleri genel olarak daha yüksek performans sergilemiştir [8].

Model	Doğruluk	Kaynak
BERTurk (fine-tuned)	~%95+	[11]
Random Forest	%93.9	[8]
SVM (TF-IDF)	~%90	[9]

3.2.2 Veri Setleri Üzerindeki Önceki Çalışmalar

- **LIME:** Ribeiro ve ark. (2016) tarafından önerilen bu yöntem, herhangi bir sınıflandırıcının tahminlerini lokal olarak açıklayabilmektedir [12].
- **SHAP:** Lundberg ve Lee (2017) oyun teorisinden esinlenerek Shapley değerlerini makine öğrenmesi açıklanabilirliğine uygulamıştır [13].
- **LLM Tabanlı Açıklama:** Son yıllarda büyük dil modellerinin (GPT, Gemini) teknik açıklamaları doğal dile çevirme kapasitesi araştırılmaktadır.

3.2.4 Çoklu Ajan Sistemleri

Wooldridge (2009) çoklu ajan sistemlerinin karmaşık görevleri modüler ve ölçeklenebilir şekilde çözmede etkinliğini ortaya koymuştur [14]. Bu projede niyet tespiti, sınıflandırma ve açıklanabilirlik görevleri ayrı ajanlara dağıtılarak modüler bir mimari elde edilmiştir.

3.2.5 Projemin Konumu

Literatürdeki çalışmalarla karşılaştırıldığında, projemizin şu anki baseline deneyleri literaür ile uygundur. Projemin özgün katkısı, 6 farklı sınıflandırma yöntemini 4 farklı veri setinde (2 dil, binary/multi-class) sistematik olarak karşılaştırması ve çoklu ajan mimarisi ile açıklanabilir yapay zeka entegrasyonu sunmasıdır.

Literatür Taraması için Kaynaklar

[1] Villanueva, K. (2024). "Comparative Study of Machine Learning Models for Sentiment Analysis: A Case of SVM, Naive Bayes, and Logistic Regression." Medium.

[2] Papers with Code. "Sentiment Analysis on IMDb Benchmark." paperswithcode.com/sota/sentiment-analysis-on-imdb

[3] "Sentiment Analysis of IMDb Movie Reviews Using Traditional Machine Learning Techniques and Transformers." ResearchGate, 2024.

[4] Keswani, S. (2024). "Transforming News Classification with BERT." Medium.

[5] "Analyzing BERT's Performance Compared to Traditional Text Classification Models." Scitepress, 2023.

[6] Acıkalın, U. ve Bardak, B. (2020). "Turkish Sentiment Analysis Using BERT." IEEE Xplore.

[7] "Towards Better Sentiment Analysis in the Turkish Language: Dataset Improvements and Model Innovations." Springer Nature, Applied Sciences, 2025.

[8] "Sentiment Analysis from Turkish News Texts with BERT-Based Language Models and Machine Learning Algorithms." ResearchGate, 2023.

[9] Saygın, Y. (2018). "A Benchmark Data for Turkish Text Categorization." TTC4900, Kaggle.

[10] Köksal (2022). "Improving automated Turkish text classification with learning-based algorithms." Concurrency and Computation: Practice and Experience, Wiley.

[11] savasy/bert-turkish-text-classification. Hugging Face Model Hub.

[12] Ribeiro, M.T., Singh, S. ve Guestrin, C. (2016). "Why Should I Trust You?: Explaining the Predictions of Any Classifier." KDD.

[13] Lundberg, S.M. ve Lee, S.I. (2017). "A Unified Approach to Interpreting Model Predictions." NeurIPS.

[14] Wooldridge, M. (2009). "An Introduction to MultiAgent Systems." John Wiley & Sons.

4. Projede kullanılan veriler, dış bağlantılar hakkında bilgiler, verilerin tamamını veya birkaç örneği gösterebilirsiniz.

Projede 4 farklı veri seti kullanılmaktadır. Tüm veri setleri HuggingFace üzerinden indirilmektedir.

4.1 Veri Setleri

Veri Seti	Dil	Görev	Sınıflar	Eğitim	Test
IMDB	İngilizce	Binary Sentiment	positive, negative	25,000	25,000
Turkish Sentiment	Türkçe	Multiclass Sentiment	pozitif, negatif, notr	440,574	48,592
AG News	İngilizce	Multiclass News	World, Sports, Business, Sci/Tech	50,000	7,600
TTC4900 Turkish News	Türkçe	Multiclass News	siyaset, dunya, ekonomi, kultur, saglik, spor, teknoloji	~3,920	~980

4.2 Veri Örnekleri

IMDB (İngilizce Binary Sentiment):

Girdi: "This movie was absolutely fantastic."

Çıktı: POSITIVE

Turkish Sentiment (Türkçe Multiclass Sentiment):

Girdi: "Bu ürün gerçekten harika, kesinlikle tavsiye ederim."

Çıktı: POZİTİF

AG News (İngilizce Multiclass News):

Girdi: "Apple announces new iPhone with revolutionary AI features."

Çıktı: TECHNOLOGY

Turkish News (Türkçe Multiclass News):

Girdi:"Galatasaray Fenerbahçe derbisini kazandı."

Çıktı: SPOR

5. Projenin ayrıntılı planı, akış şeması, veri işleyişi vs., projede karşılaşılan sorunlar, projenin şu andaki durumu (varsa prototip veya ekran çıktıları), bundan sonra yapılacaklar

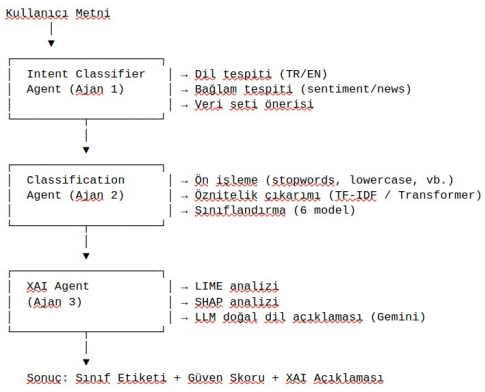

Çoklu Ajan Destekli Açıklanabilir Yapay Zeka Metin Sınıflandırma Sistemi

Detaylı Sistem Akış Şeması

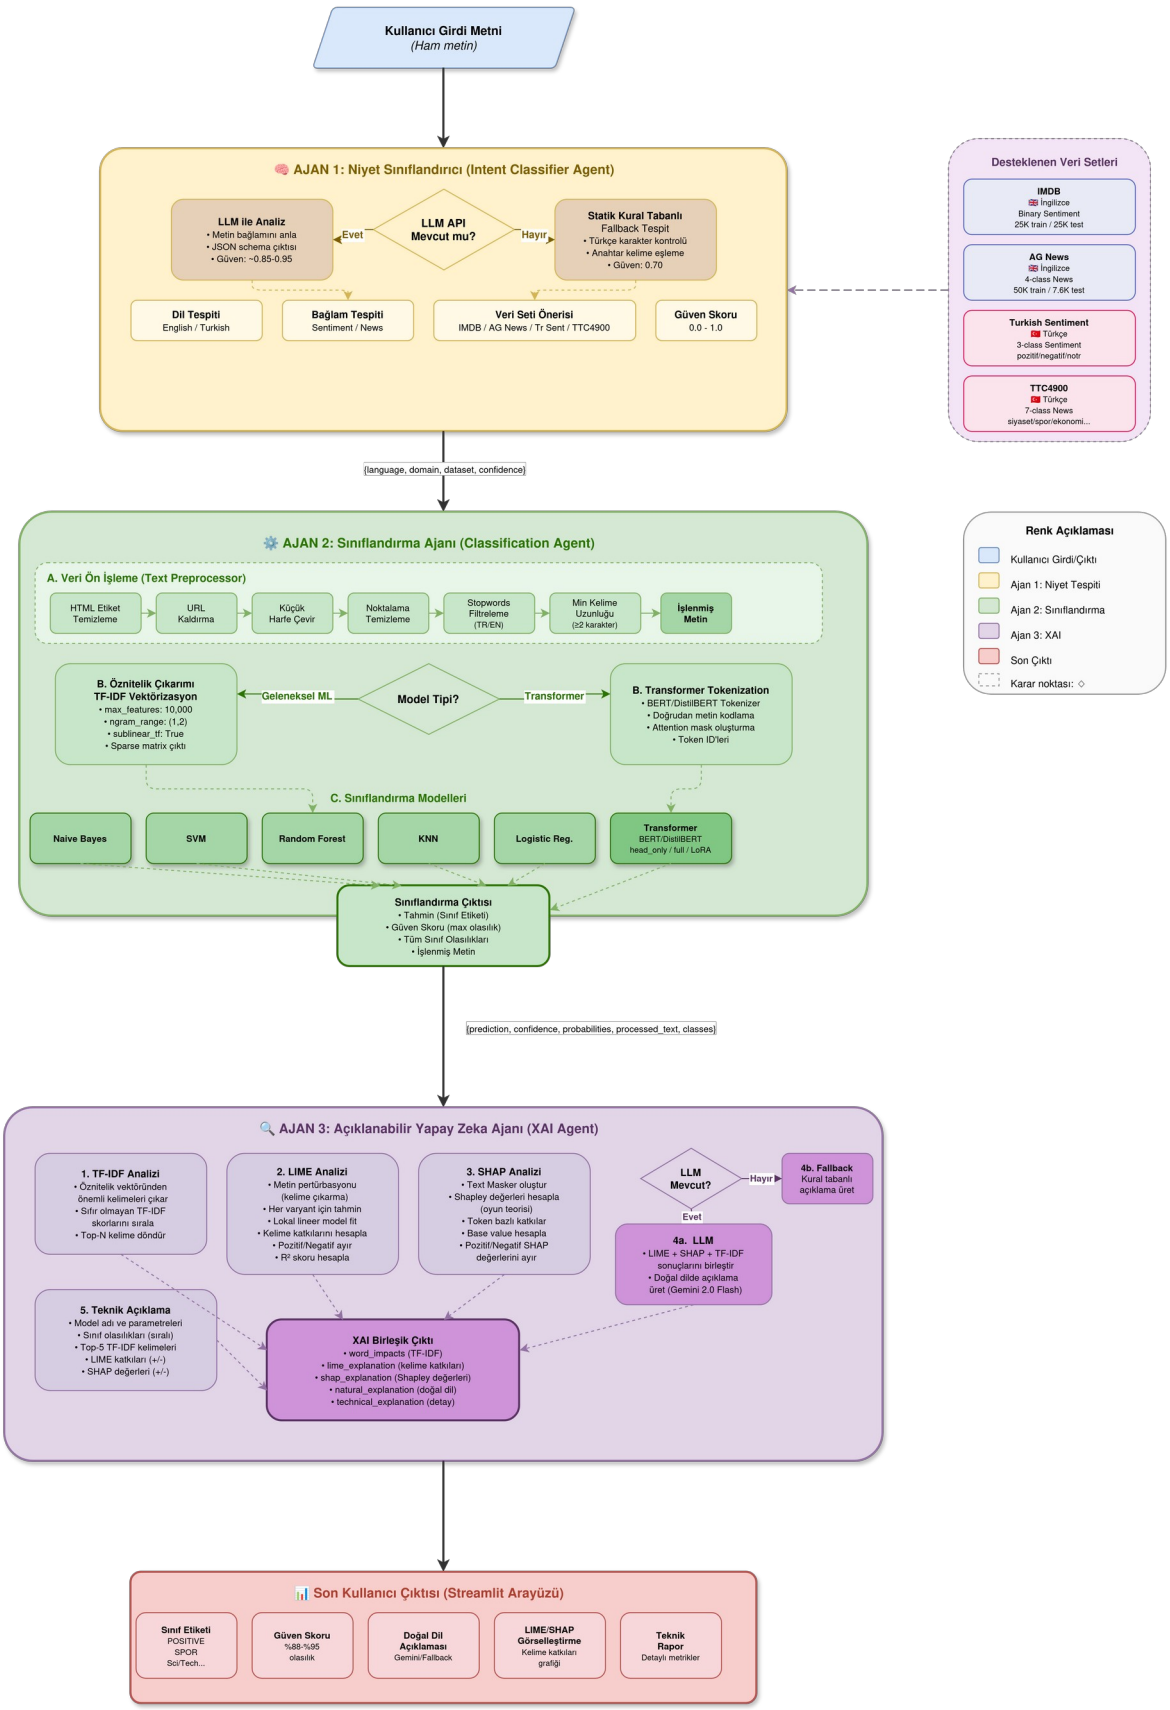

5.2 Tamamlanan Çalışmalar (Hafta 1-6)

Hafta 1-2 (23 Ocak - 5 Şubat): Veri Seti Seçimi ve Ön İşleme

- 4 veri seti (IMDB, Turkish Sentiment, AG News, Turkish News TTC4900) belirlendi ve HuggingFace üzerinden indirildi.
- Metin ön işleme modülü geliştirildi (HTML temizleme, URL kaldırma, stopwords filtreleme, Türkçe/İngilizce dil desteği).
- Veri indirme ve ön işleme scriptleri (download_datasets.py, preprocess_datasets.py) oluşturuldu.
- YAML tabanlı konfigürasyon sistemi kuruldu (her veri seti için ayrı config dosyası).

Hafta 3-4 (6 - 19 Şubat): TF-IDF ve Model Eğitimi

- TF-IDF öznitelik çıkarımı modülü tamamlandı (10,000 öznitelik, bigram desteği, sublinear TF).
- 5 geleneksel ML modeli (Naive Bayes, SVM, Random Forest, KNN, Logistic Regression) implement edildi.
- Her model için abstract base class tasarlandı (train, predict, predict_proba, save, load).
- 3 ajanlı mimari (Intent Classifier, Classification Agent, XAI Agent) implement edildi.
- LIME ve SHAP açıklanabilirlik yöntemleri XAI Agent içinde entegre edildi.
- LLM tabanlı açıklama üretimi API ile sağlandı.
- Tüm veri setleri üzerinde model eğitimi yapıldı, sonuçlar JSON formatında kaydedildi.
- Config-driven eğitim pipeline'ı (train_experiment.py) geliştirildi.
- Streamlit arayüzü geliştirildi (7 sayfa: Ana Sayfa, Metin Sınıflandırma, Toplu İşleme, Model Karşılaştırma, Veri Seti Gezgini, Deney Detayları, Model Eğitimi).

Hafta 5-6 (20 Şubat - 1 Mart): Transformer Implementasyonu

- TransformerClassifier modülü tamamlandı (BERT/DistilBERT desteği).
- 3 fine-tuning stratejisi implement edildi: head_only, full fine-tuning, LoRA (Low-Rank Adaptation).
- GPU/CPU donanım tespiti ve cihaz seçimi modülü (hardware.py) geliştirildi.
- VRAM/RAM bilgisi gösterimi Streamlit arayüzüne eklendi.
- Conda environment yönetimine geçiş yapıldı (environment.yml).

5.3 Karşılaşılan Sorunlar

KNN Hesaplama Maliyeti: KNN algoritması tahmin aşamasında tüm eğitim verisine karşı mesafe hesaplaması yaptığından, büyük veri setlerinde (özellikle 50,000 örnekli IMDB ve AG News) hem bellek tüketimi hem de çıkarım süresi ciddi şekilde arttı. ball_tree algoritması ve distance-weighted voting kullanılarak kısmen iyileştirildi, ancak KNN diğer modellere kıyasla enyavaş tahmin süresine sahip olmaya devam etti.

Bellek Yönetimi: Büyük veri setlerinde (50,000+ örnek) TF-IDF matrislerinin bellek tüketimi yüksek olabilmektedir. Sparse matrix kullanımı ile çözüldü.

Niyet Sınıflandırıcı Veri Kısıtı: Niyet sınıflandırma için etiketli veri seti bulmak zordu. Gemini LLM ile zero-shot yaklaşım ve statik kural tabanlı fallback mekanizması uygulandı.

5.4 Projenin Şu Andaki Durumu

Proje planına göre Hafta 1-6 hedefleri tamamlanmıştır. Mevcut sistem tam fonksiyonel durumda olup:

- 6 sınıflandırma modeli implement ve eğitilmiştir.
- 3 ajanlı mimari çalışır durumdadır.
- LIME, SHAP ve LLM açıklanabilirlik yöntemleri entegre edilmiştir.
- Streamlit arayüzü 7 sayfa ile kullanıma hazırdır.
- 4 veri setinde deneyler başarıyla tamamlanmıştır.

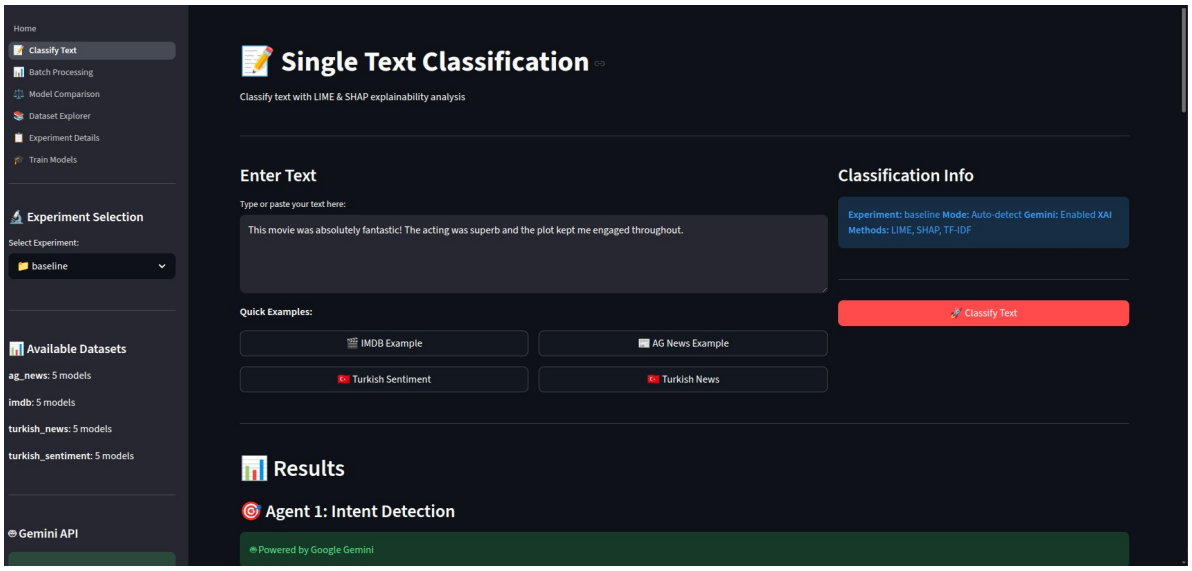

Ekran Görüntüsü 1 - Metin Sınıflandırma Sayfası (Girdi Ekranı):
Classify Text sayfasında sol panelde deney seçimi (baseline) ve 4 veri seti (ag_news, imdb, turkish_news, turkish_sentiment - her biri 5 eğitilmiş model ile) listelenmektedir. Ortada metin giriş alanı bulunmakta olup, kullanıcı doğrudan metin yazabilir veya "Quick Examples" butonları (IMDB, AG News, Turkish Sentiment, Turkish News) ile örnek test metinler yükleyebilir. Bu metinler bu datasetlerde olabilecek test metinlerdir. Sağ tarafta sınıflandırma bilgisi (deney adı, mod, XAI yöntemleri) ve "Classify Text" butonu yer almaktadır.

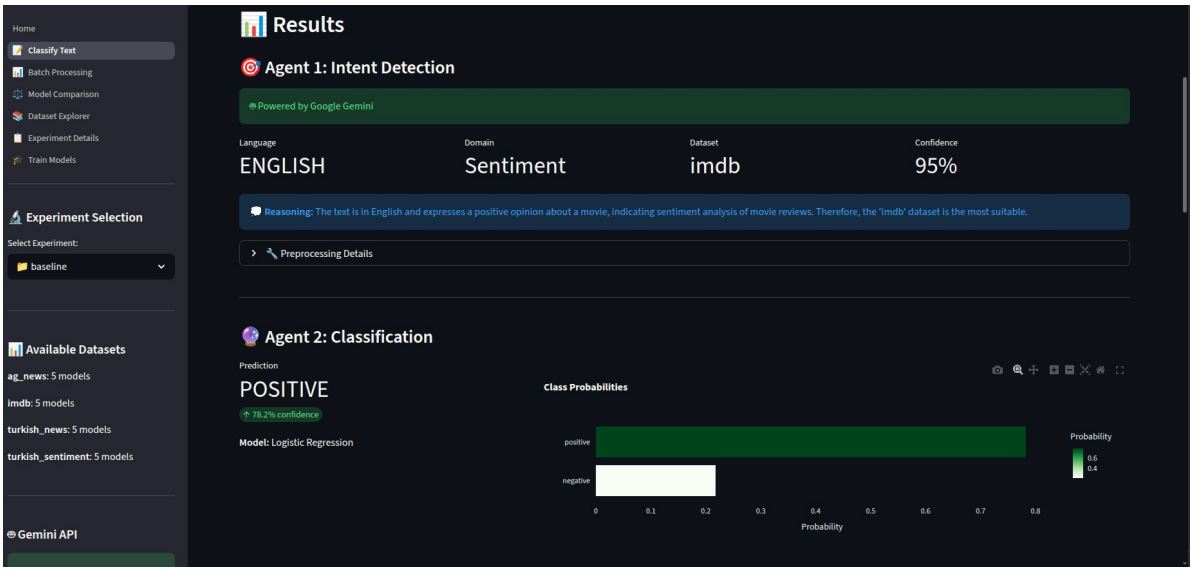

Ekran Görüntüsü 2 - Ajan 1 ve Ajan 2 Sonuçları (Niyet Tespiti ve Sınıflandırma):
Agent 1 (Intent Detection): LLM kullanılarak giriş metninin dili ENGLISH, bağlamı Sentiment, önerilen veri seti imdb ve güven skoru %95 olarak tespit edilmiştir. Reasoning alanında "The text is in English and expresses a positive opinion about a movie, indicating sentiment analysis of movie reviews" açıklaması verilmiştir. Agent 2 (Classification): Logistic Regression modeli ile metin POSITIVE olarak sınıflandırılmış, %78.2 güven skoru elde edilmiştir. Sınıf olasılıkları yatay bar chart ile görselleştirilmiştir

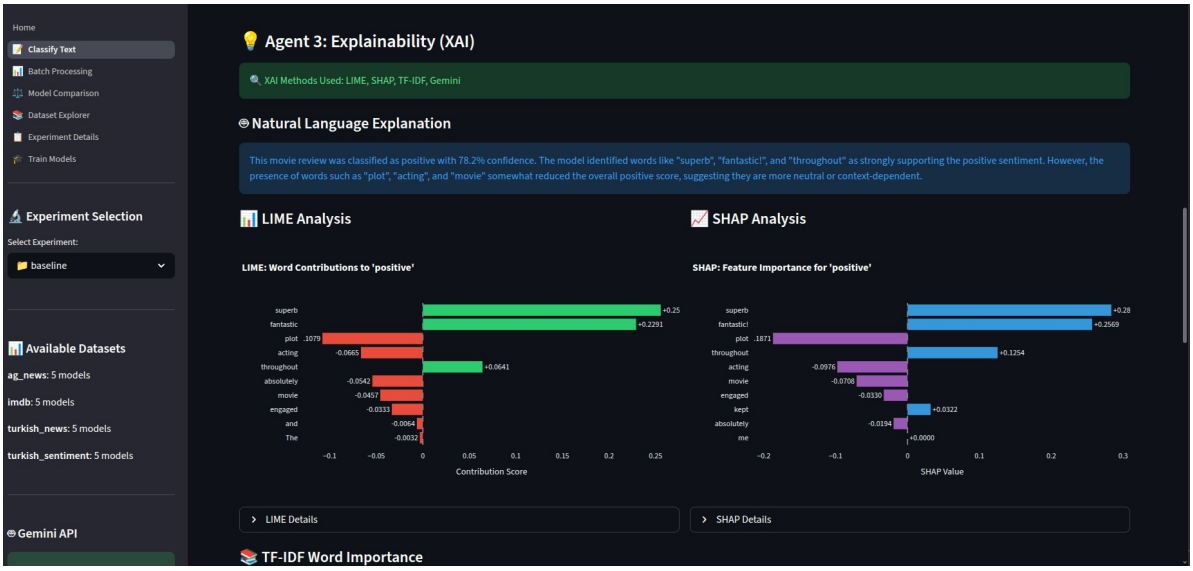

Ekran Görüntüsü 3 - Ajan 3 Sonuçları (Açıklanabilir Yapay Zeka):
Agent 3 (XAI): Üç farklı açıklanabilirlik yöntemi ile sonuçlar sunulmaktadır. Doğal dil açıklaması LLM tarafından üretilmiş olup, "superb", "fantastic" ve "throughout" kelimelerinin pozitif duyguyu desteklediği belirtilmiştir. LIME analizi grafiğinde "superb" (+0.25) ve "fantastic" (+0.23) en yüksek pozitif katkıya sahipken, "plot" (-0.08) ve "acting" (-0.07) negatif katkı göstermiştir. SHAP analizi benzer şekilde kelime bazlı Shapley değerlerini görselleştirmiştir. Altta TF-IDF Word Importance bölümü yer almaktadır.

5.5 Bundan Sonra Yapılacaklar

Dönem	Tarih	Hedef
Hafta 7-8	3 - 16 Mart	Niyet Tespiti ajanının iyileştirilmesi, zero-shot'tan supervised learning'e geçiş stratejisi
Hafta 9-10	17 - 30 Mart	LLM Agent entegrasyonunun güçlendirilmesi, demo hazırlığı
Hafta 11	31 Mart - 7 Nisan	K-fold cross validation, detaylı performans analizleri, IEEE formatında final rapor yazımı
Final Teslimatı	8 Nisan 2026	IEEE formatında final rapor ve demo sunumu

Kalan görevler:

- K-fold cross validation ile model performanslarının daha güvenilir değerlendirilmesi
- Transformer modellerinin tüm veri setlerinde eğitimi ve karşılaştırması
- Birim testlerin yazılması
- IEEE formatında final raporun hazırlanması
- Demo sunumunun hazırlanması